

Introducción a las Redes Neuronales Artificiales y el Deep Learning

Autor: Escuela de Inteligencia Artificial – Campus Digital

El Perceptrón y sus Limitaciones

El perceptrón, propuesto por Frank Rosenblatt en 1958, es la unidad computacional básica de las redes neuronales artificiales. Inspirado en el funcionamiento de la neurona biológica, el perceptrón realiza una suma ponderada de sus entradas, aplica una función de activación y produce una salida binaria. A pesar de su elegante simpleza, el perceptrón simple solo es capaz de resolver problemas linealmente separables, limitación que Minsky y Papert formalizaron matemáticamente en 1969 en su influyente obra.

La superación de esta limitación requirió el desarrollo de redes multicapa con algoritmos de entrenamiento basados en la retropropagación del error (backpropagation), cuya formulación eficiente por Rumelhart, Hinton y Williams en 1986 abrió el camino hacia las arquitecturas profundas modernas.

Arquitecturas Modernas

Las redes neuronales convolucionales (CNN), las redes recurrentes (RNN, LSTM, GRU) y, más recientemente, los Transformers han redefinido los límites de lo que es computacionalmente posible en tareas de percepción e inteligencia artificial general.

La arquitectura Transformer, introducida por Vaswani et al. en el seminal artículo "Attention Is All You Need" (2017), ha resultado ser la base sobre la que se han construido los modelos de lenguaje de gran escala (LLM) más avanzados de la actualidad, desde GPT-4 hasta Claude, Gemini o LLaMA, demostrando una versatilidad y escalabilidad sin precedentes en la historia del aprendizaje automático.

Entrenamiento y Optimización

El entrenamiento de redes neuronales profundas es un problema de optimización no convexo de alta dimensionalidad, abordado en la práctica mediante variantes estocásticas del descenso de gradiente. Optimizadores adaptativos como Adam, RMSprop o AdaFactor han sustituido al SGD clásico en la mayoría de aplicaciones modernas, gracias a su capacidad para ajustar automáticamente la tasa de aprendizaje por parámetro.

La regularización mediante dropout, batch normalization, weight decay y data augmentation es esencial para prevenir el sobreajuste (overfitting) y garantizar la generalización de los modelos a

datos no vistos durante el entrenamiento.