

Proyecto Fin de Máster: Detección de Desinformación en Redes Sociales mediante NLP

Autor/Organismo: Máster en Ciencia de Datos – Universidad Miguel Hernández de Elche

Resumen

El presente proyecto aborda el problema de la detección automática de desinformación en publicaciones de Twitter en lengua española, mediante el entrenamiento y evaluación comparativa de modelos de procesamiento de lenguaje natural. Se han evaluado cuatro aproximaciones distintas: un clasificador Naive Bayes sobre representación TF-IDF como línea base, una red LSTM bidireccional con embeddings preentrenados FastText en español, el modelo BERT multilingüe (mBERT) ajustado por fine-tuning, y la versión en español del modelo RoBERTa (RoBERTa-es) ajustada sobre el conjunto de datos FakeDeS.

Los resultados obtenidos demuestran la superioridad de los modelos basados en Transformers, con RoBERTa-es alcanzando un F1-score de 0,891 sobre el conjunto de test, frente al 0,634 del clasificador Naive Bayes de referencia.

Conjunto de Datos y Preprocesamiento

El dataset utilizado para el entrenamiento y la evaluación es una combinación del corpus FakeDeS (1.200 noticias falsas y 1.200 noticias verdaderas verificadas) con una colección propia de 3.400 tuits etiquetados manualmente por dos anotadores independientes con un índice de acuerdo Kappa de Cohen de 0,78, considerado acuerdo sustancial.

El preprocesamiento aplicado incluye la normalización de menciones y URLs, la eliminación de duplicados y near-duplicates mediante MinHash LSH, la corrección de errores ortográficos frecuentes en redes sociales, y la gestión del desbalanceo de clases mediante técnicas de oversampling SMOTE adaptado al dominio textual.

Conclusiones y Trabajo Futuro

Los resultados obtenidos confirman que el fine-tuning de modelos preentrenados de gran escala representa el estado del arte para la detección de desinformación en español. No obstante, se identifican limitaciones importantes: la sensibilidad al dominio temático (los modelos degradan su rendimiento significativamente cuando se evalúan sobre noticias de temática diferente a la del entrenamiento) y la necesidad de actualización continua ante la evolución de las estrategias de desinformación.

Como líneas de trabajo futuro se propone la exploración de arquitecturas multimodales que integren el análisis de imágenes adjuntas, el desarrollo de métodos de explicabilidad que permitan identificar los patrones lingüísticos más discriminativos, y la construcción de un benchmark

específico para el contexto mediático español.